

URL의 구조적 특징이 피싱 URL 판별 가능성에 미치는 영향

— PhishTank 제보 URL 과 주요 사이트 URL 의 비교 분석 —

SKT K-Digital Training · AI 활용 역량 과정 과제 10

작성자: 심희현

작성일: 2026년 9월 8일

초록

피싱 공격은 여전히 가장 흔한 사이버 보안 위협 중 하나이며, 사용자가 URL 만 보고 위험을 판단해야 하는 경우가 많다. 본 연구는 "URL의 구조적 특징(길이, 특수문자 수, 서브도메인 수, IP 주소 사용 여부, HTTPS 사용 여부)이 해당 URL이 피싱 URL로 판별될 가능성에 영향을 준다"는 가설을 세우고 이를 검증했다. PhishTank에 실시간으로 제보된 피싱 의심 URL 68건과 트래픽 상위 사이트의 정상 URL 69건, 총 137건을 수집해 URL 문자열에서 11개의 구조적 특징을 직접 추출하고 Mann-Whitney U 검정과 Fisher의 정확검정으로 두 집단을 비교했다. 그 결과 URL 길이(중앙값 33 대 24, $p < 0.001$), 하이픈 개수($p < 0.001$), HTTPS 미사용 비율($p = 0.006$)에서 피싱 URL이 유의하게 더 위험한 패턴을 보였다. 반면 서브도메인 수, 슬래시 개수, 경로 길이는 오히려 정상 URL 쪽이 더 높게 나타나 가설과 반대 방향이었으며, 이는 표본 구성의 한계(정상 URL에 의도적으로 깊은 경로를 포함시킨 점)에서 비롯된 것으로 보인다. IP 주소 직접 사용이나 '@' 기호는 두 집단 모두에서 관측되지 않았다. 이 연구는 URL 길이·하이픈·HTTPS 여부가 실질적인 판별 신호가 될 수 있음을 확인하는 동시에, 소규모·비무작위 표본에서 구조적 특징의 방향성이 뒤집힐 수 있다는 한계도 함께 보여준다.

1. 서론

1.1 관심 분야

관심 분야는 웹 보안(Web Security)이며, 그중에서도 사용자가 URL 만 보고 위험 여부를 가늠하는 '피싱 URL 탐지' 문제로 좁혔다.

1.2 검토한 후보 주제와 접은 이유

AI(Claude)에게 웹 보안 분야에서 확인 가능한 질문 10 개를 뽑아 달라고 요청한 뒤, '일주일 안에 직접 데이터를 모을 수 있는가', '실제 사이트에 대한 무단 공격 없이 합법적으로 수행 가능한가' 두 기준으로 걸러 4 개 후보로 좁혔다. 최종적으로 선택하지 않은 3 개 후보와 접은 이유는 다음과 같다.

후보 주제	접은 이유
사이트 유형(정부/쇼핑몰/커뮤니티)별 보안 헤더 적용률 차이	사이트를 유형별로 대표성 있게 분류할 기준이 애매하고, 일주일 안에 신뢰할 만한 표본을 모으기 어려움
사이트 유형별 쿠키 보안 속성(Secure/HttpOnly/SameSite) 적용률 차이	위와 동일한 표본 분류 문제에 더해, 쿠키는 로그인 세션이 있어야 관찰되는 경우가 많아 비로그인 상태로는 데이터가 제한적임
DVWA 난이도별 XSS 공격 성공률	실행은 쉽지만 난이도에 따라 필터 강도가 이미 설계된 환경이라 '발견'보다는 '확인'에 가까워 연구로서의 흥미가 낮음

1.3 최종 가설

URL 의 구조적 특징(길이, 특수문자 개수, 서브도메인 개수, IP 주소 사용 여부, HTTPS 사용 여부)이 해당 URL 이 피싱 URL 로 판별될 가능성에 영향을 준다.

이 가설에서 '무엇이 무엇에 영향을 주는가'는 명확하다: URL 문자열에서 관찰 가능한 구조적 특징(독립변수)이 피싱 여부라는 이진 판별 결과(종속변수)에 영향을 준다는 것이다.

1.4 측정 방법

각 URL 에 대해 다음을 코드로 자동 추출해 수치화했다: (1) 전체 문자 길이, (2) 점(.)의 개수, (3) 하이픈(-) 개수, (4) 숫자 개수, (5) 특수문자(@ % = & ? _ ~ , + * # \$!) 개수, (6) 슬래시(/) 개수, (7) 경로(path) 길이, (8) 서브도메인 개수(호스트명의 레이블 수 - 2), (9) 호스트명이 IP 주소 형태인지 여부, (10) HTTPS 사용 여부, (11) '@' 기호 포함 여부.

1.5 가설이 틀렸다면 나올 결과

가설이 틀렸다면 피싱 URL 과 정상 URL 사이에 구조적 특징의 분포 차이가 통계적으로 유의하지 않거나($p \geq 0.05$), 오히려 정상 URL 쪽이 더 길거나 복잡한 구조를 가진 것으로 나타날 것이다.

1.6 데이터 수집 범위 및 기간

2026 년 9 월 8 일 하루 동안의 스냅샷으로, PhishTank 의 '최근 제보(Recent

Submissions)' 화면에 나타난 URL 중 잘림 없이 전체가 확인되는 68 건과, 검색 엔진·SNS·이커머스·금융·정부·교육 등 각 영역의 잘 알려진 상위 트래픽 사이트에서 수집한 정상 URL 69 건, 총 137 건(중복 제거 후 137 건)을 사용했다.

1.7 AI 와 가설을 다듬은 과정

AI가 먼저 웹 보안 분야의 확인 가능한 질문 10 개를 제시했고, 실행 가능성 기준으로 6 개로 추린 뒤 4 개의 가설 후보 문장(보안 헤더, 쿠키, XSS 성공률, 피싱 URL 특징)으로 다듬었다. 이후 연구자가 4 개 중 '피싱 URL 특징 분석'을 최종적으로 선택했고, AI가 해당 방향에 맞춰 측정 항목과 반증 조건을 구체화했다.

1.8 이 가설을 최종으로 고른 이유

다른 후보들과 달리 (1) 이미 공개적으로 제보·집계되는 데이터(PhishTank)를 활용할 수 있어 표본 확보가 확실하고, (2) 실제 웹사이트에 대한 공격이나 침입 시도 없이 URL 문자열 관찰만으로 검증이 가능하며, (3) 결과가 가설을 지지하든 기각하든 피싱 탐지 관점에서 실질적인 의미를 가지기 때문이다.

2. 방법

2.1 선행연구 검토

AI에게 가설과 관련된 선행 연구를 물어본 뒤, 검색 엔진으로 각 문헌의 제목·저자·발표 매체를 직접 검색해 실제로 존재하는지, 초록의 내용이 실제로 그런 주장을 하는지를 확인했다. 이 과정에서 존재가 확인되지 않거나 본문 접근이 불가능한 몇 개의 후보(예: 사전 추출된 특징만 제공하고 원본 URL 문자열을 제공하지 않는 일부 GitHub 저장소 기반 데이터셋 소개 자료)는 '내가 직접 URL에서 특징을 추출한다'는 본 연구의 방법론과 맞지 않아 참고문헌에서 제외했다.

저자(연도)	출처	이 문헌이 가설의 어느 부분을 뒷받침하는가
Marchal, François, State & Engel (2014)	IEEE Transactions on Network and Service Management, 11(4)	URL 자체의 구조적 특징만으로 피싱 여부를 스트리밍 방식으로 탐지할 수 있음을 보여 실험 방법론(원가설의 측정 방식)을 뒷받침함
Kulkarni & Brown (2019)	International Journal of Advanced Computer Science and Applications, 10(7)	URL 기반 특징으로 4개 분류기 모두 90% 이상의 구분 정확도를 보여, URL 구조적 특징이 피싱 판별에 실제로 유의미함을 뒷받침함
Le Pochat, Van Goethem, Tajalizadehkhoob, Korczyński & Joosen (2019)	NDSS 2019 (Tranco 랭킹)	정상 사이트 표본을 상위 트래픽 순위 기준으로 구성하는 것이 보안 연구에서 표준적인 방법임을 뒷받침 (본 연구의 정상 URL 표집 방식의 근거)
Javeed, Aslam, Sadiqa, Raza, Iqbal & Akram (2025)	Journal of Computing & Biomedical Informatics, 9(1)	Random Forest 등 머신러닝 기반 URL 판별에서 97.7%의 정확도를 보고, URL 구조적 특징 중요도 분석이 유효한 접근임을 뒷받침

이미 알려진 사실: 위 선행연구들은 URL의 어휘적·구조적 특징(길이, 특수문자, 서브도메인 수 등)만으로도 상당한 수준(90%~97.7%)의 피싱/정상 분류가 가능하다는 것을 이미 보여주었다. 새로 주장하는 것: 본 연구는 기존 연구처럼 대규모 머신러닝 모델을 학습시키는 것이 아니라, 소규모(137건) 표본에서 개별 특징 각각이 통계적으로 유의한 차이를 보이는지, 그리고 어떤 특징은 오히려 통설과 반대 방향으로 나타나는지를 가설 검정 방식으로 직접 확인했다는 점에서 차별화된다.

2.2 실험 설계 및 실행

항목	내용
바꾼 조건(독립변수)	URL의 출처 집단 (피싱 제보 URL vs. 정상 상위 트래픽 사이트 URL)
고정한 조건	동일한 특징 추출 코드(Python, urllib.parse 기반)를 두 집단에 동일하게 적용; 수집 시점(2026-09-08)을 동일하게 고정
표본 수	피싱 68건, 정상 69건 (총 137건, 중복 제거 후)
측정한 값	URL 길이, 점 개수, 하이픈 개수, 숫자 개수, 특수문자 개수, 슬래시 개수, 경로 길이, 서브도메인 개수, IP 주소 사용 여부, HTTPS 사용 여부, '@' 기호 포함 여부 (총 11개 특징)
공개 데이터 출처	피싱: PhishTank(phishtank.org, rss.phishtank.com, checkurl.phishtank.com, phishtank.net) 최근 제보 목록 / 정상: 검색 엔진


	·SNS·이커머스·금융·정부·국제기구·교육 분야의 잘 알려진 상위 트래픽 사이트
받은 날짜	2026 년 9 월 8 일
실행 절차	Python 스크립트(analyze.py)로 CSV 원자료를 읽어 특징을 추출하고, scipy.stats 로 Mann-Whitney U 검정(연속형 8 개 특징) 및 Fisher 의 정확검정(이진형 3 개 특징)을 수행. 재현 패키지에 원자료와 스크립트를 모두 포함.


도중에 설계를 바꾼 점: 이진 변수(IP 주소 사용 여부, HTTPS 사용 여부)에 대해 처음에는 카이제곱 검정만 계획했으나, 정상 URL 집단에서 HTTPS 사용이 100%로 나타나 기대빈도 표에 0 인 칸이 발생해 카이제곱 검정이 성립하지 않았다. 이에 따라 기대빈도가 5 미만인 경우 Fisher 의 정확검정으로 전환하도록 스크립트를 수정했다.

3. 결과

11 개 특징에 대한 검정 결과는 아래 표와 같다. 유의수준은 0.05 를 기준으로 판단했다.

특징	검정	피싱 (중앙값/평균)	정상 (중앙값/평균)	통계량	p 값	유의 (p<.05)
URL 길이	Mann-Whitney U	33 / 32.41	24 / 26.12	3579.5	<0.001	예
점(.) 개수	Mann-Whitney U	2 / 1.81	2 / 1.91	1925.0	0.029	예
하이픈(-) 개수	Mann-Whitney U	0 / 0.44	0 / 0.03	3131.0	<0.001	예
숫자 개수	Mann-Whitney U	0 / 0.24	0 / 0.07	2549.0	0.053	아니오
특수문자 개수	Mann-Whitney U	0 / 0.00	0 / 0.04	2278.0	0.162	아니오
슬래시(/) 개수	Mann-Whitney U	3 / 2.76	3 / 3.25	1525.5	<0.001	예
경로 길이	Mann-Whitney U	1 / 2.26	1 / 3.83	1797.5	0.006	예
서브도메인 개수	Mann-Whitney U	1 / 0.68	1 / 0.88	1835.0	0.006	예
IP 주소 사용	Fisher 정확검정	0% / 0.0%	0% / 0.0%	-	1.000	아니오
HTTPS 미사용률	Fisher 정확검정	10.3% 미사용	0% 미사용	-	0.006	예
'@' 기호 포함	Fisher 정확검정	0% / 0.0%	0% / 0.0%	-	1.000	아니오





3.1 가설대로 나온 부분

URL 길이는 피싱 URL 이 유의하게 더 길었다(중앙값 33 대 24, $p < 0.001$). 하이픈 개수도 피싱 URL 에서 유의하게 많았다(평균 0.44 대 0.03, $p < 0.001$) — 실제로 'bpcreditohs.top', 'keep-wifi.com'처럼 브랜드명을 훔쳐 내며 하이픈으로 단어를 잇는 패턴이 다수 관측되었다. HTTPS 미사용 비율도 피싱 URL(10.3%)에서만 나타났고 정상 URL(0%)에서는 전혀 나타나지 않아 통계적으로 유의했다($p = 0.006$).

3.2 가설과 다르게 나온 부분

슬래시 개수($p < 0.001$), 경로 길이($p = 0.006$), 서브도메인 개수($p = 0.006$), 점 개수($p = 0.029$)는 모두 통계적으로 유의했지만 방향이 가설과 반대였다 — 정상 URL 쪽이 더 높은 값을 보였다. 숫자 개수($p = 0.053$)와 특수문자 개수($p = 0.162$)는 유의한 차이가 없었다. IP 주소 직접 사용과 '@' 기호는 두 집단 모두에서 단 한 건도 관측되지 않아 이번 표본으로는 판별력을 확인할 수 없었다.

3.3 판단의 근거

이 판단은 features_full.csv 에 저장된 137 건 각각의 원자료 값과, 이를 집계한 statistical_results.csv 의 검정 통계량·p 값에 근거한다. 예를 들어 경로 길이가 반대 방향으로 나온 것은 정상 URL 표본에 'en.wikipedia.org/wiki/Computer_security'처럼 의도적으로 깊은 경로를 포함시켰기 때문으로, 원자료를 직접 확인해 그 원인을 특정할 수 있었다.

3.4 가설을 고친 과정

최초 가설 문장은 'URL 이 복잡할수록(길고, 특수문자가 많고, 서브도메인이 많을수록) 피싱일 가능성이 높다'는 단일 방향 가설이었다. 그러나 서브도메인·경로·슬래시 지표가 반대로 나오는 것을 확인한 뒤, 가설을 '길이·하이픈·HTTPS 여부는 피싱과 연관되지만, 서브도메인·경로 구조는 표본 구성에 따라 방향이 달라질 수 있다'는 조건부 형태로 수정했다. 즉 가설을 데이터에 맞게 고쳤으며, 고치기 전과 후를 모두 위와 같이 기록했다.

3.5 최종 결론

종합하면, URL의 구조적 특징은 피싱 여부와 무관하지 않다는 원가설의 큰 방향은 지지되었다. 특히 URL 길이, 하이픈 사용, HTTPS 미사용은 이번 표본에서 일관되게 피싱 URL과 연관되어, 실무적으로 사용자 교육이나 자동 경고 시스템에서 우선적으로 참고할 만한 신호로 판단된다. 그러나 서브도메인 수나 경로 길이처럼 '복잡할수록 위험하다'는 통념과 반대로 나온 특징들도 있어, 이 가설을 단일 규칙(예: '경로가 길면 위험하다')으로 단순화하는 것은 이번 데이터로는 뒷받침되지 않는다. 즉 URL 구조적 특징의 영향력은 특징별로 방향과 크기가 다르며, 하나의 지표만으로 피싱 여부를 판단하는 것은 위험하다는 결론에 도달했다.

3.6 이 연구로 말할 수 없는 것 (한계)

- 표본 크기가 137 건으로 작고, 피싱 URL은 PhishTank의 '제보' 단계(커뮤니티 검증 이전) 데이터를 포함해 실제로는 오탐(정상 사이트가 잘못 제보됨)이 섞였을 가능성을 배제할 수 없다.
- 정상 URL 표본은 무작위 웹 브라우징이 아니라 연구자가 다양성을 위해 의도적으로 선택한 상위 트래픽 사이트와 그 하위 페이지로 구성되어, 실제 사용자가 일상적으로 접하는 URL 분포와 다를 수 있다(특히 경로 길이·서브도메인 지표가 이 영향을 크게 받은 것으로 보인다).
- 단일 시점(2026년 9월 8일) 스냅샷이므로 시간에 따른 피싱 URL 패턴의 변화는 반영하지 못한다.
- URL 문자열 특징만 사용했을 뿐 웹페이지 콘텐츠, WHOIS, 인증서 정보 등은 포함하지 않아, 실제 피싱 탐지 시스템 수준의 종합 판단과는 거리가 있다.
- 본 연구는 상관관계를 통계적으로 확인한 것이며, 인과관계(예: '하이픈을 넣으면 피싱이 된다')를 주장하지 않는다.

4. 참고문헌

Marchal, S., François, J., State, R., & Engel, T. (2014). PhishStorm: Detecting Phishing with Streaming Analytics. *IEEE Transactions on Network and Service Management*, 11(4), 458-471.

Kulkarni, A., & Brown III, L. L. (2019). Phishing Websites Detection using Machine Learning. *International Journal of Advanced Computer Science and Applications*, 10(7).

Le Pochat, V., Van Goethem, T., Tajalizadehkhoob, S., Korczyński, M., & Joosen, W. (2019). Tranco: A Research-Oriented Top Sites Ranking Hardened Against Manipulation. *Proceedings of the 26th Annual Network and Distributed System Security Symposium (NDSS 2019)*.

Javeed, M. U., Aslam, S. M., Sadiqa, H. A., Raza, A., Iqbal, M. M., & Akram, M. (2025). Phishing Website URL Detection Using a Hybrid Machine Learning Approach. *Journal of Computing & Biomedical Informatics*, 9(1).

PhishTank. (2026). Recent Submissions [Data set]. Retrieved September 8, 2026, from <https://www.phishtank.org/>

제외한 문헌: 사전 추출된 특징(원본 URL 문자열 비공개)만 제공하는 일부 Kaggle/GitHub 기반 데이터셋 소개 글은, 본 연구가 URL 문자열에서 직접 특징을 추출하는 방법론을 취하기 때문에 참고문헌에서 제외했다.

참고문헌 확인 방법: 각 문헌의 제목과 저자명을 검색 엔진으로 직접 검색해 실제 학술지·학회·기관 페이지에서 존재를 확인했고, 초록 또는 데이터셋 설명 페이지의 내용이 위 표에 적은 연결 내용과 일치하는지 대조했다.

5. 재현 방법 (Reproducibility)

재현 패키지 ZIP에는 다음이 포함되어 있다:

- phishing_urls_raw.csv — PhishTank에서 수집한 원자료 68 건 (url, label, source, collected_date)
- legitimate_urls_raw.csv — 정상 URL 원자료 69 건 (url, label, source, collected_date)
- analyze.py — 특징 추출 및 통계 검정을 수행하는 Python 스크립트
- features_full.csv — 137 건 전체의 추출된 특징값
- statistical_results.csv — 11개 특징에 대한 검정 결과 요약
- boxplots_continuous_features.png, barchart_binary_features.png — 결과 시각화

재현 절차

- (1) Python 3.12 환경에 pandas, numpy, scipy, matplotlib을 설치한다.
- (2) 두 개의 raw csv 파일과 analyze.py를 같은 폴더에 둔다.
- (3) 'python analyze.py'를 실행하면 features_full.csv, statistical_results.csv, 두 개의 png 파일이 재생성된다.
- (4) 원자료의 건수($68+69=137$)가 본문의 표본 수와 일치하는지 확인한다.

짧은 확인 방법: statistical_results.csv를 열어 url_length 행의 p_value가 $1.05e-07$ 근처인지, uses_https 행의 p_value가 0.0063 근처인지 확인하면 재현이 성공했다고 판단할 수 있다.